

Paper2CoreCode: Fine-Tuning Qwen2.5-Coder-7B for Paper-to-Code Generation

但杰, 蒋佳媛, 高鑫彤, 徐媛

2026 年 7 月 4 日

目录

1	项目概述	2
1.1	核心能力	2
2	模型微调报告	2
2.1	训练配置	2
2.2	训练结果	2
2.3	模型权重	3
3	数据说明	3
3.1	训练集	3
3.2	测试集	3
4	评测结果报告	3
4.1	核心指标对比	3
4.2	消融实验	3
4.2.1	基座模型对比（固定 4-bit QLoRA）	3
4.2.2	量化方案对比（固定 Qwen2.5-Coder-7B-Instruct）	4
5	分工信息	4

1 项目概述

本项目旨在将学术论文的文本描述自动转换为可执行的 PyTorch 核心模型代码。我们基于 Qwen2.5-Coder-7B-Instruct，使用 90 篇 2024 年顶级机器学习会议论文（ICLR/ICML/NeurIPS）构建的 SFT 数据集进行 LoRA/QLoRA 微调。最终，在独立的 75 篇 2025 年论文测试集上，我们系统性地评测了微调模型与基座模型的性能差异，并完成了 5 种基座模型 × 4 种量化方案的消融实验，验证了技术路线的有效性。项目的仓库在 [paper2corecode](#)。由于某些技术原因，模型尚未上传至 HuggingFace。

1.1 核心能力

- 输入: 论文核心文本 (Abstract + Body)
- 输出: `<file>` 标签包裹的、去除了工程脚手架的纯净 PyTorch 模型代码。

2 模型微调报告

2.1 训练配置

训练采用 LLaMA-Factory 框架，在单张 NVIDIA A100 (80GB) GPU 上进行 4-bit QLoRA 微调。

配置项	值
基础模型	Qwen/Qwen2.5-Coder-7B-Instruct
微调方式	LoRA (4-bit 量化 QLoRA)
LoRA 目标模块	all (所有线性层)
训练阶段	SFT (Supervised Fine-Tuning)
训练轮数	8 epochs
学习率	2.0e-4
Batch Size	2 (per device)
梯度累积	8 steps
截断长度	2048 tokens
混合精度	FP16
梯度检查点	启用

表 1: 训练配置

配置文件: `programs/fine_tuning/training/train_qwen.yaml`

2.2 训练结果

- 最终训练损失 (`train_loss`): 0.5489
- 训练耗时 (`train_runtime`): 9 分 41 秒

2.3 模型权重

- *HuggingFace* (完整模型): Anyadanyuan/Qwen2.5-7B-paper2XCode
- *HuggingFace* (LoRA 适配器): Anyadanyuan/Qwen2.5-7B-paper2XCode-lora

3 数据说明

3.1 训练集

- 规模: 90 篇 2024 年 ICLR/ICML/NeurIPS 论文
- 构建流程: 采用 ACPP (Algorithm Code Purification Pipeline) 管线, 对每篇论文的官方 GitHub 仓库进行代码提纯, 与论文文本配对, 生成 Alpaca 格式数据。
- 文件: data/train_dataset.json

3.2 测试集

- 规模: 75 篇 2025 年 ICLR/ICML/NeurIPS 论文 (与训练集无交集)
- 构建流程: build_test_set_correct.py 脚本自动从 PDF 提取文本、从 GitHub 克隆参考代码, 零 API 成本。
- 文件: data/test_dataset.json

4 评测结果报告

在 75 篇论文的测试集上, 我们对比了微调模型与基座模型的性能。

4.1 核心指标对比

指标	基座模型	微调模型	提升 (pp)
可执行率 (XPR)	9.4%	14.7%	+5.3
语法正确率 (SYR)	39.1%	34.7%	-4.4
论文组件覆盖率 (PCR)	9.8%	16.2%	+6.4
CodeBERTScore	0.380	0.444	+0.064
总分 (Overall)	16.1%	20.5%	+4.4

表 2: 评测结果核心指标对比

数据来源: data/evaluation_results/*/summary.json

4.2 消融实验

为验证技术选型的合理性, 我们进行了 5 种基座模型 $\times$ 4 种量化方案的消融实验。

4.2.1 基座模型对比 (固定 4-bit QLoRA)

基座模型	XPR	SYR	CodeBERTScore	Overall	峰值显存
Qwen2.5-Coder-7B-Instruct	14.7%	34.7%	0.444	20.5%	13.2 GB
Qwen2.5-7B-Instruct	15.2%	30.6%	0.467	19.8%	13.5 GB
DeepSeek-Coder-V2-Lite (16B MoE)	13.5%	33.0%	0.432	19.2%	13.8 GB
CodeLlama-7b-Instruct	20.7%	30.4%	0.428	20.3%	13.0 GB
Mistral-7B-Instruct-v0.3	16.3%	27.7%	0.443	18.5%	13.1 GB

表 3: 基座模型消融实验结果

4.2.2 量化方案对比（固定 Qwen2.5-Coder-7B-Instruct）

量化方案	XPR	SYR	CodeBERTScore	Overall	峰值显存	训练耗时
BF16 全参数微调	15.2%	35.1%	0.450	21.1%	31.5 GB	45.3 min
BF16 + LoRA	14.9%	32.9%	0.431	20.4%	18.2 GB	1.9 min
8-bit QLoRA	14.8%	32.0%	0.485	21.0%	14.2 GB	4.0 min
4-bit QLoRA	14.7%	34.7%	0.444	20.5%	13.2 GB	2.6 min

表 4: 量化方案消融实验结果

5 分工信息

姓名	贡献
但杰	评测体系设计，消融实验，报告撰写
蒋佳媛	模型微调，训练脚本与监控重构，数据集构建
高鑫彤	ACPP 代码提纯管线设计与实现，数据清洗
徐媛	推理脚本与服务器部署，项目管理与整合

表 5: 分工信息